BIOINFORMATIKA:

PREDIKSI STRUKTUR SEKUNDER PROTEIN MENGGUNAKAN SUPPORT VECTOR MACHINE PADA DATASET RS126



Muhammad Ilham Ibadurrohman

14/366093/PA/16211

PROGRAM STUDI ILMU KOMPUTER DEPARTEMEN ILMU KOMPUTER DAN ELEKTRONIKA

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM UNIVERSITAS GADJAH MADA 2019

GitHub Link: https://github.com/nopedude/SVM PSSP/tree/master/SVM PSSP

PENGOLAHAN DATA:

Dataset RS126 dibuka dan diolah dengan menggunakan bahasa pemrograman python. dari dataset tersebut, line ganjil merujuk pada struktur primer protein dan line genap merujuk pada struktur sekunder dari struktur primer.

Contoh pembacaan data struktur primer:

Contoh pembacaan data struktur sekunder:

PENCARIAN DATA YANG TIDAK LENGKAP:

Pengecekan terhadap data dilakukan untuk melihat apakah terdapat perbedaan jumlah karakter struktur primer dan sekunder (karena prediksi struktur sekunder termasuk ke dalam permasalahan sequence labelling, maka dipastikan jumlah karakter dari struktur primer dan struktur sekunder selalu sama).

```
In [5]: for i in range(len(raw_sekunder)):
  len1 = len(raw_sekunder[i])
  len2 = len(raw_primer[i])
  if(len1 != len2):
   print(i," ", raw_sekunder[i]," ",raw_primer[i])
   RKRLNRPLTLSEKIVYGHLDDPANQEIERGKTYLRLRPDRVAMQDATAQMAMLQFISSGLPKVAVPSTIHCDHLIEAQL
```

Setelah dilakukan pengecekan, ditemukan bahwa data pada urutan urutan 109 memiliki panjang struktur primer dan sekunder yang berbeda. Karena hanya ada 1 data maka data struktur primer dan struktur sekunder dari urutan ke 109 tersebut kita hapus dengan cara melakukan operasi pop.

```
In [6]:
        raw primer.pop(109)
        raw_sekunder.pop(109)
        count sekunder = 0
        count_primer = 0
        for i in range(len(raw_sekunder)):
            len1 = len(raw_sekunder[i])
            len2 = len(raw_primer[i])
            count_sekunder = count_sekunder + len1
            count_primer = count_primer + len2
            if(len1 != len2):
                print(i," ", raw_sekunder[i]," ",raw_primer[i])
        print("count struktur sekunder : ",count_sekunder)
        print("count struktur primer : ",count_primer)
        count struktur sekunder: 22594
        count struktur primer: 22594
```

ORTHOGONAL ENCODING:

Target Labeling Untuk setiap data struktur primer dan sekunder dilakukan split sehingga dapat diencode kedalam bentuk orthogonal.

```
In [7]: def split(sequence):
    return [char for char in sequence]

In [8]: split_primer = []
    split_sekunder = []
    for i in range(len(raw_primer)):
        split_primer.append(split(raw_primer[i]))
        split_sekunder.append(split(raw_sekunder[i]))
```

Hasil operasi split struktur primer dan struktur sekunder protein kemudian diubah kedalam bentuk Orthogonal Encoding dan Target Labeling. Cuplikan switch case untuk setiap asam amino pada struktur primer protein ditampilkan sebagai berikut:

```
'L' : np.array([0,0,0,0,0,0,0,0,0,1,0,0,0,0,0,0,0,0,0]),
               'N' : np.array([0,0,0,0,0,0,0,0,0,0,1,0,0,0,0,0,0,0,0]),
               'Q' : np.array([0,0,0,0,0,0,0,0,0,0,0,1,0,0,0,0,0,0,0]),
              'P' : np.array([0,0,0,0,0,0,0,0,0,0,0,0,0,1,0,0,0,0,0]),
               'R' : np.array([0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0]),
               'T' : np.array([0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0]),
               'V' : np.array([0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,1,0]),
              'Y' : np.array([0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0,0])
           }
           return switch.get(arg)
        def orthogonal sekunder(arg):
           switch = {
               'H' : 0,
              'C' : 1,
              'E' : 2
           return switch.get(arg)
In [10]: for i in range(len(split_primer)):
           seq = split primer[i]
           for j in range(len(seq)):
              seq[j] = orthogonal_primer(seq[j])
```

```
In [12]: for i in range(len(split_sekunder)):
              seq2 = split sekunder[i]
              for j in range(len(seq2)):
                  seq2[j] = orthogonal_sekunder(seq2[j])
In [13]: split_sekunder
Out[13]: [[1,
            1,
            2,
            2,
            2,
            2,
            2,
            1,
            1,
            1,
            1,
```

```
In [14]: def target(lis):
             Y = []
             for i in range(len(lis)):
                  for j in range(len(lis[i])):
                      Y.append(lis[i][j])
              return Y
In [15]: y_label = target(split_sekunder)
         y_label
Out[15]:
         [1,
          1,
          2,
          2,
           2,
          2,
          2,
          1,
```

DATASET

Label dan Fitur Setiap hasil split dari struktur sekunder protein akan dijadikan label/target class. Dari hasil operasi tersebut didapatkan total keseluruhan label berjumlah 22.594. Angka ini akan digunakan untuk memastikan bahwa dataset juga memiliki jumlah fitur yang sama.

```
In [16]: len(y_label)
Out[16]: 22594
```

Pembentukan fitur data dilakukan dengan menggunakan fungsi window_padding_data. Fungsi ini akan menerima ukuran dari sliding window dan sekuens struktur primer protein. Pada fungsi ini, fitur akan diolah seperti penambahan padding 0 di awal dan diakhir dan pengambilan fitur-fitur hasil windowing sehingga data keluaran bisa langsung dilatih pada model SVM.

```
In [17]: def window_padding_data(size, sequence):
          num = int(size/2)
           for i in range(len(sequence)):
              for j in range(num):
                 sequence[i].append(zeros)
                 sequence[i].insert(0, zeros)
           X = []
           temp = []
           for k in range(len(sequence)):
              for 1 in range(len(sequence[k])-(size-1)):
                 temp = sequence[k][1:1+size]
                 X.append(temp)
                 temp = []
           return X
       <
```

Contoh penggunaan fungsi padding:

```
In [18]: X = window_padding_data(13,split_primer)
In [19]: len(X)
Out[19]: 22594
```

Dimana data struktur primer protein akan diolah dengan variabel ukuran sliding window SVM. Sebelum dimasukkan ke model SVM Scikit-Learn, data di reshape untuk mengikuti ukuran input dari model.

```
In [20]: X = np.array(X)
y_label = np.array(y_label)
X = X.reshape(22594, 13*20)
```

Sebelum data dimasukkan ke model SVM Scikit-Learn, data di reshape untuk mengikuti ukuran input dari model. Data direshape menjadi ukuran 22.594 data dikali dengan 100 (x ukuran window dan 20 ukuran orthogonal encoding.)

```
In [20]: X = np.array(X)
y_label = np.array(y_label)
X = X.reshape(22594, 13*20)

In [26]: #Data di split menjadi 2, training dan testing data. Kemudian dihitung dengan SV

In [22]: from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y_label, test_size = 0.20

In [23]: from sklearn.svm import SVC
from sklearn.metrics import classification_report

In [24]: svc = SVC(kernel='rbf', gamma = 0.1, C=1.5)
svc.fit(X_train, y_train)
y_pred = svc.predict(X_test)
y_true = y_test
print(classification_report(y_true,y_pred))
```

HASIL:

Ukuran		Classification Report							
Window									
		precision	recall	f1-score	support				
3	0	0.54	0.48	0.51	1458				
	1	0.60	0.76	0.67	2050				
	2	0.49	0.30	0.37	1011				
	accuracy			0.57	4519				
	macro avg	0.54	0.51	0.52	4519				
	weighted avg	0.56	0.57	0.55	4519				
5		precision	recall	f1-score	support				
	0	0.57	0.53	0.55	1477				
	1	0.63	0.75	0.68	2047				
	2	0.51	0.37	0.43	995				
	accuracy			0.59	4519				
	macro avg	0.57	0.55	0.55	4519				
	weighted avg	0.58	0.59	0.58	4519				
		precision	recall	f1-score	support				
	0	0.59	0.58	0.59	1389				
	1	0.63	0.73	0.68	2025				
7	2	0.58	0.41	0.48	1105				
	accuracy			0.61	4519				
	macro avg	0.60	0.58	0.58	4519				
	weighted avg	0.61	0.61	0.60	4519				
9		precision	recall	f1-score	support				
	0	0.62	0.57	0.59	1479				
	1	0.63	0.75	0.68	2006				
	2	0.54	0.41	0.47	1034				
	accuracy			0.61	4519				
	macro avg	0.60	0.57	0.58	4519				
	weighted avg	0.61	0.61	0.60	4519				

						_
		precision	recall	f1-score	support	
	0	0.61	0.57		1465	
	1	0.63	0.75		2007	
11	2	0.56	0.41	0.48	1047	
				0.60	4540	
	accuracy	0.60	0.50	0.62	4519	
	macro avg	0.60	0.58		4519	
	weighted avg	0.61	0.62	0.61	4519	
		precision	recall	f1-score	support	
		0.63	0.50	0.61	1400	
	0	0.63	0.59		1492	
13	1	0.62	0.76		1974	
	2	0.59	0.41	0.48	1053	
	accuracy			0.62	4519	
	macro avg	0.62	0.59		4519	
	weighted avg	0.62	0.62	0.61	4519	
	g					
		precision	recall	f1-score	support	
	0	0.60	0.60	0.60	1420	
	1	0.65			2037	
15	2	0.57	0.73	0.47	1062	
	2	0.57	0.40	0.47	1002	
	accuracy			0.62	4519	
	macro avg	0.61	0.58		4519	
	weighted avg		0.62	0.61	4519	
		precision	recall	f1-score	support	
	0	0.62	0.62	0.62	1421	
17	1	0.66		0.70	2052	
	2	0.58	0.42	0.49	1046	
(Terbaik)						
	accuracy			0.63	4519	
	macro avg	0.62	0.60	0.60	4519	
	weighted avg	0.63	0.63	0.62	4519	
19		precision	recall	f1-score	support	
	0	0.63	0.59	0.61	1455	
	1	0.64	0.77	0.70	2005	
	2	0.61	0.41	0.49	1059	
	accuracy			0.63	4519	
	macro avg	0.62	0.59	0.60	4519	
	weighted avg	0.63	0.63	0.62	4519	